

Ecologia de Paisagens com R



Darren Norris

23 de junho de 2026

Índice

Preface

1	Introduction	1
2	Quantificando a Estrutura da Paisagem	2
2.1	Apresentação	2
2.1.1	Objetivos do Capítulo	2
2.2	Pacotes e dados	3
2.3	Mapa Campus Marco Zero	4
2.4	Métricas da paisagem e pacote “landscapemetrics”	6
2.5	Escala e a caracterização da paisagem	11
2.5.1	Diversidade	11
2.5.2	Composição	14
2.5.3	Configuração	17
2.5.4	Implicações para a Fauna:	20
2.6	Conclusão da Análise	20
3	Escala de Efeito na Ocorrência de Fauna Doméstica	22
3.1	Introdução	22
3.2	Configuração do Ambiente e Dados	22
3.3	Análise da Escala de Efeito	23
3.3.1	Rumo ao Desenho Quase-Experimental	28
3.4	Conclusão	28
4	Summary	29
	References	30

Preface

This is a Quarto book.

To learn more about Quarto books visit <https://quarto.org/docs/books>.

1 + 1

[1] 2

1 Introduction

This is a book created from markdown and executable code.

To complete....

```
1 + 1
```

```
[1] 2
```

2 Quantificando a Estrutura da Paisagem

 Capítulo em Desenvolvimento

Aviso:

Este capítulo é um trabalho em andamento. Os exemplos de código e o texto ainda estão sendo refinados. Você pode encontrar alguns espaços em branco, rascunhos, erros gramaticais, mas estou trabalhando ativamente para finalizá-lo. Feedbacks e sugestões são sempre bem-vindos!

2.1 Apresentação

Neste capítulo, nosso foco será a aplicação prática. Utilizaremos o Campus Marco Zero da UNIFAP como laboratório de estudo. Vamos avançar além do cálculo de métricas em pontos isoladas, como fizemos no Capítulo [Métricas da paisagem](#). Vamos implementar fluxos de trabalho automatizados. Isso permitirá analisar vários pontos em múltiplas escalas simultaneamente.

Para lidar com a complexidade espacial sem nos perdermos tempo em tarefas repetitivas, adotaremos o fluxo de trabalho do tidyverse aplicado ao espaço. O grande diferencial aqui será o uso da lógica **Split-Apply-Combine** (Dividir-Aplicar-Combinar). Em vez de calcular métricas manualmente para cada ponto e cada raio de monitoramento, criaremos scripts que automatizam esse processo para locais diferentes e em múltiplas escalas espaciais simultaneamente.

O foco aqui não é a teoria, mas sim como construir um fluxo de trabalho (workflow) eficiente que permita responder perguntas biológicas reais: Qual a escala espacial mais relevante para a caracterização da paisagem que estou estudando? Para isso, adotaremos o paradigma Split-Apply-Combine, uma estratégia poderosa para automatizar análises repetitivas, permitindo que você processe dezenas de pontos amostrais com o mesmo esforço que processaria um só.

2.1.1 Objetivos do Capítulo

Nesta etapa da nossa jornada, você aprenderá a:

1. **Dominar o conceito de “Mapeamento”:** Entender a transição da álgebra de mapas para a programação funcional (usando o pacote purrr).
2. **Quantificar a Paisagem:** Calcular métricas essenciais de **Diversidade, Composição e Configuração** através do pacote landscapemetrics.

3. **Analisar o Efeito de Escala:** Construir visualizações que revelam como a caracterização da paisagem muda conforme aumentamos o raio de observação ao redor de um ponto.
4. **Interpretar Dados para a Fauna:** Traduzir gráficos de métricas espaciais em conclusões biológicas sobre conectividade e qualidade de habitat para espécies especialistas e generalistas.

Box Didático: O Duplo Sentido de ‘Mapear’

Quando usamos a função `purrr::map()` para extrair as métricas das nossas pontos, estamos a deparar-nos com um encontro entre a Ciência da Computação a Ecologia Espacial e a Cartografia. Porque é que a função de iteração se chama “map”?

1. O Mapeamento Matemático (A Origem do Código) Na programação e na matemática, “mapear” (*mapping*) não significa desenhar continentes. Significa **associar rigorosamente cada elemento de um conjunto a um elemento de outro conjunto**. Se tem os números [1, 2, 3] e aplica uma regra de “multiplicar por 2”, “mapeou” esses valores para um novo conjunto: [2, 4, 6]. A função `purrr::map()` faz exatamente isso: pega no nosso conjunto de pontos (conjunto A) e aplica uma função matemática a cada uma delas para gerar um novo conjunto de Métricas (conjunto B).

2. O Mapeamento Cartográfico (O Espaço Físico) Na geografia, um “mapa” faz a mesma coisa, mas com o mundo físico. Um cartógrafo “mapeia” o espaço real associando cada árvore, rio ou estrada do mundo tridimensional (conjunto A) a uma coordenada plana de latitude e longitude no papel (conjunto B).

3. O Encontro na Ecologia da Paisagem No nosso script, unimos estes dois mundos. Quando corremos o `purrr::map()`, estamos a **mapear matematicamente o nosso mapa espacial**. Pegamos numa localização no espaço real (o *buffer* de 50 metros em redor de uma armadilha fotografica) e transformamo-la num conceito abstrato: um número que representa a caracterização do espaço (a métrica de paisagem).

Esta mesma lógica é o coração da **Álgebra de Mapas** (criada por Dana Tomlin nos anos 1980 [[@tomlin1990geographic](#)]), que é o que o pacote `terra` usa por trás dos panos . Quando somamos dois *rasters* ou os recortamos, o computador está simplesmente a “mapear” uma regra matemática sobre cada pequeno píxel da imagem, transformando o uso do solo em dados quantitativos.

2.2 Pacotes e dados

Pacotes.

```
# 1. Project Data
library(eprdados)

# 2. Spatial Engines
library(terra)
library(sf)
library(landscapemetrics)
```

```
# 3. Data Manipulation & Grammar
library(tidyverse)

# 4. Analytical Models
library(mgcv)
library(Hmisc)

# 5. Cartography & Visualization
library(tmap)
library(mapview)
```

Dados.

```
# Carregando os dados do pacote eprdados
fmz <- system.file("vector/marco_zero_2026_31982.gpkg", package="eprdados")
# load polygon
campus <- st_read(fmz, layer = "campus")
```

```
Reading layer `campus' from data source
  `/home/runner/work/_temp/Library/eprdados/vector/marco_zero_2026_31982.gpkg'
  using driver `GPKG'
Simple feature collection with 1 feature and 7 fields
Geometry type: MULTIPOLYGON
Dimension:      XY
Bounding box:   xmin: 490095.5 ymin: 9998870 xmax: 490890.4 ymax: 10000190
Projected CRS: SIRGAS 2000 / UTM zone 22S
```

```
cameras <- st_read(fmz, layer = "ep_species_pa")
```

```
Reading layer `ep_species_pa' from data source
  `/home/runner/work/_temp/Library/eprdados/vector/marco_zero_2026_31982.gpkg'
  using driver `GPKG'
Simple feature collection with 17 features and 13 fields
Geometry type: POINT
Dimension:      XY
Bounding box:   xmin: 490193.3 ymin: 9998883 xmax: 490793.2 ymax: 9999686
Projected CRS: SIRGAS 2000 / UTM zone 22S
```

2.3 Mapa Campus Marco Zero

A figura abaixo apresenta a distribuição espacial das armadilhas fotograficas. (Nota: Uma versão interativa deste mapa está disponível na versão online deste livro [Clique aqui para ver o mapa](#)).




Figura 2.1: Localização das armadilhas fotográficas (cameras) no Campus Marco Zero.

2.4 Métricas da paisagem e pacote “landscapemetrics”

O pacote `landscapemetrics` tem funções para calcular métricas de paisagem em paisagens categóricas (onde tem uma classificação de cobertura de terra/habitat - modelo mancha-corredor-matriz), em um fluxo de trabalho organizado (Hesselbarth et al. 2019). Existem diversos tutoriais e exemplos no site do próprio pacote: <https://r-spatialecology.github.io/landscapemetrics/>.

Desafio - O Paradigma Split-Apply-Combine em Ecologia Espacial Antes de escrevermos qualquer linha de código, precisamos entender a estratégia que estamos usando para resolver problemas complexos. Em 2011, foi formalizado no R um conceito chamado Split-Apply-Combine (Dividir, Aplicar e Combinar).

A família `map()` do pacote `purrr` foi projetada especificamente para iterar sobre essas estruturas complexas com muito mais segurança e velocidade. Ao dominar essa lógica, vocês não estão apenas aprendendo a rodar métricas de paisagem; vocês estão ganhando um modelo mental poderoso que pode ser usado para rodar modelos climáticos, processar milhares de arquivos de áudio, ou analisar grandes bancos de metadados genéticos.

A ideia central é simples: quando um desafio analítico é grande demais ou consome muita memória do computador, nós não tentamos resolvê-lo de uma vez só. Nós o quebramos em três etapas lógicas:

1. SPLIT (Dividir) Em vez de tentar processar o raster de uso do solo do estado inteiro de uma vez, nós dividimos o problema.

No nosso código: O argumento `.x = pontos_sf$id_ponto` faz o Split. Ele separa o nosso conjunto de dados de 17 pontos de amostragem e diz ao computador: “Esqueça o todo; olhe apenas para o Ponto 1 agora”.

2. APPLY (Aplicar) Uma vez que o problema foi reduzido a um pedaço gerenciável, nós aplicamos a nossa análise (a nossa função “trabalhadora”) apenas àquele pedaço.


No nosso código: A função `processar_uma_camera` faz o Apply. Ela pega aquele ponto isolado, recorta um mini-raster (crop) ao seu redor e calcula as métricas (`sample_lsm`) para as escalas de 25, 50 e 100 metros. O computador faz isso sorrindo, porque processar um único ponto exige quase zero de memória RAM.

3. COMBINE (Combinar) O R agora tem 17 pequenos resultados flutuando soltos na memória. A etapa final é costurar todos eles de volta em um formato útil.

No nosso código: A função final `purrr::list_rbind()` faz o Combine. Ela recolhe as 17 pequenas tabelas individuais que foram geradas no passo anterior e as empilha perfeitamente em um único Data Frame final, pronto para ser exportado ou visualizado no `ggplot2`.

Carregar classificação.


```
class_5 <- rast(class_5)
plot(class_5)
```



```
# Verificamos se o raster é reconhecido pelo landscapemetrics
check_landscape(class_5)
```

```
      layer      crs units  class n_classes OK
1        1 projected    m integer         5  v
```

```
class_3 <- rast(class_3)
plot(class_3)
```



```
# Verificamos se o raster é reconhecido pelo landscapemetrics
check_landscape(class_3)
```

```
layer      crs units  class n_classes OK
1         1 projected    m integer      3  v
```

Especificar escala (raios).

```
# Definimos os raios (buffers) em metros para escala (12.5, 25, 50 e 100).
escalas_metros <- c(12.5, 25, 50, 100)
```

Especificar metricas.

```
# metricas desejados
# composição - o que e quanto tem
metrics_comp <- c("lsm_l_ta", "lsm_c_cpand", "lsm_c_pland", "lsm_c_ca")
# configuração - "como" classes são organizados e distribuídos no espaço.
metrics_conf <- c("lsm_c_ed", "lsm_c_ai")
# diversidade da paisagem
metrics_div <- "lsm_l_shdi"
what_metricas <- c(metrics_comp, metrics_conf, metrics_div)
```

Abordagem split-apply-combine. Sempre que precisarem repetir uma análise para dezenas de polígonos, pontos ou imagens, isolem o que identifica o local no .x. Todo o resto da base de dados espacial (como os rasters) entra como argumento estático logo abaixo. Isso mantém o código limpo, rápido e mais fácil de ler.

```

processar_uma_camera <- function(id_alvo, pontos_totais, raster_cheio,
                                escalas_alvo) {

  # 1. Isola apenas a câmera atual
  ponto_atual <- pontos_totais |> filter(instal_ponto == id_alvo)

  # 2. Recorta o raster (Proteção de Memória)
  raio_max <- max(escalas_alvo) + 10
  buffer_local <- sf::st_buffer(ponto_atual, dist = raio_max)
  raster_local <- terra::crop(raster_cheio, terra::ext(buffer_local))

  # 3. Calcula as métricas para as três escalas
  # Usamos map_dfr internamente para evitar o erro de vetor do landscapemetrics!
  resultados <- purrr::map_dfr(escalas_alvo, function(raio) {

    temp <- landscapemetrics::sample_lsm(
      landscape = raster_local,
      y = ponto_atual,
      plot_id = id_alvo,
      shape = "circle",
      size = raio,
      what = what_metricas
    )

    temp$escala_buffer <- raio # Adiciona a coluna da escala
    return(temp)

  })

  # 4. Faxina (Obrigatório para o purrr não travar o PC)
  rm(raster_local, buffer_local, ponto_atual)
  gc(verbose = FALSE)
  terra::tmpFiles(current = TRUE, remove = TRUE)

  # Devolve apenas a tabela com resultados
  return(resultados)
}

# 0 fluxo para rodar
# (17 pontos x 7 metricas x 4 escalas):
tabela_metricas_final <- purrr::map(
  # 0 'map' pega cada ID coluna instal_ponto e joga dentro do 1º argumento da função: 'id_alvo'
  .x = cameras$instal_ponto,
  # a função

```

```

.f = processar_uma_camera,
# Argumentos FIXOS da função
# 0 'map' pega esses três dados e os envia exatamente para o
# 2º, 3º e 4º argumentos da nossa função, sem alterar nada.
pontos_totais = cameras,
raster_cheio = class_3,
escalas_alvo = escalas_metros,
# barra de progresso
.progress = "Cáculando métricas"
) |>
  purrr::list_rbind()

#Incluindo os nomes das classes
tabela_fatores <- cats(class_3)[[1]]

tabela_metricas_final <- tabela_metricas_final |>
  left_join(tabela_fatores, by = c("class" = "value")) |>
  # Opcional: Reorganizando as colunas para o nome da categoria ficar perto do ID
  relocate(class_3, .after = class)

# Export
if(!dir.exists("data")) dir.create("data", showWarnings = FALSE)
write.csv(tabela_metricas_final,
          "data/tabela_metricas_final.csv", row.names = FALSE)

```

Entendendo a Mágica do `purrr::map()`: O Dinâmico vs. O Fixo Quando criamos a nossa função `processar_uma_camera()`, nós definimos que ela precisa de exatamente quatro “ingredientes” para funcionar:

`id_alvo`: O número da câmera que será processada agora.

`pontos_totais`: O mapa vetorial com todas as câmeras.

`raster_cheio`: A imagem contendo o uso do solo.

`escalas_alvo`: Os raios de extração (25m, 50m, 100m).

O desafio é: nós temos 17 câmeras. Como dizemos ao R para rodar essa função 17 vezes sem termos que copiar e colar o código 17 vezes? É aqui que entra o `purrr::map()`. Pensem nele como um gerente de uma linha de montagem inteligente que divide os ingredientes entre o que muda e o que fica fixo.

1. A Esteira Rolante (O Argumento Dinâmico) Observem que dentro do comando `map()`, nós não escrevemos `id_alvo = ...`. Em vez disso, nós passamos a coluna com todos os IDs para o argumento `.x` (`.x = pontos_sf$id_ponto`).

Essa é a regra de ouro do map: Ele pega todos os itens que você colocou no .x e os entrega, um por um, diretamente no primeiro argumento da sua função. * Na primeira rodada, o map() pega a Câmera 1 e injeta no id_alvo. A função processa.

Na segunda rodada, ele pega a Câmera 2 e injeta no id_alvo.

Ele funciona como uma esteira rolante, alimentando a função até a lista acabar.

2. As Ferramentas Constantes (Os Argumentos Estáticos) Os outros três ingredientes (pontos_totais, raster_cheio e escalas_alvo) não mudam nunca. Não importa se o R está processando a primeira ou a última câmera, a imagem de satélite de fundo e as escalas de 25m, 50m e 100m serão exatamente as mesmas.

Por isso, nós escrevemos esses argumentos com seus nomes exatos na parte de baixo do map(). O R entende que eles são ferramentas fixas da bancada de trabalho e os entrega iguazinhos em todas as iterações.

Quando os alunos visualizarem a tabela_resultados, eles encontrarão uma estrutura de dados “tidy” (longa), que é perfeita para o ggplot2. As colunas mais importantes que eles precisam compreender são:

plot_id: Representa qual dos 17 pontos está sendo analisado (o centro do buffer).

class: Qual classe de uso do solo (ex: 1 = Floresta, 2 = Água, 3 = Área Urbana) a linha representa.

metric: O nome da métrica calculada (ex: pland para Percentage of Landscape).

value: O valor matemático da métrica.

escala_buffer: O tamanho da paisagem ao redor do ponto (25, 50 ou 100).

2.5 Escala e a caracterização da paisagem

2.5.1 Diversidade

```
# Ler o arquivo com metricas
dados_metricas <- read_csv("data/tabela_metricas_final.csv")

# Filtrar os dados
dados_div <- dados_metricas %>%
  # Filtrar apenas a métrica de diversidade (shdi)
  filter(metric == "shdi")

grafico_escala_div <- ggplot(dados_div,
                             aes(x = escala_buffer, y = value)) +
  # 1. Pontos Brutos
  geom_jitter(alpha = 0.3, width = 1.5, size = 1.5) +
  # 2. Crossbar
```

```

# Adicionamos aes(group = escala_buffer) LOCALMENTE.
# Isso avisa ao ggplot: "Para calcular a média e o bootstrap, agrupe por escala.
# Mas não estrague a continuidade do eixo X para o resto do gráfico".
stat_summary(
  aes(group = escala_buffer),
  fun.data = "mean_cl_boot",
  geom = "crossbar",
  alpha = 0.4,
  color = "black",
  linewidth = 0.6
) +

# 3. Linha de Tendência (Loess)
# Como o agrupamento foi isolado no crossbar, o loess consegue enxergar
# a distância contínua (ex: o salto maior de 50m para 100m) e desenha a curva.
stat_smooth(
  method = "loess",
  se = FALSE,
  linewidth = 1.2,
  color = "black" # Forçamos a linha para preto para destacar sobre os pontos coloridos
) +
scale_color_viridis_d(option = "turbo") +
scale_fill_viridis_d(option = "turbo") +
labs(
  title = "Efeito de Escala na Diversidade da Paisagem",
  subtitle = "Variação contínua e tendência (Média ± IC 95%)",
  x = "Raio de Amostragem (metros)",
  y = "Diversidade (Shannon)"
) +
theme_bw() +
theme(
  legend.position = "none",
  strip.text = element_text(face = "bold", size = 11),
  # Aumentar a clareza visual mantendo apenas as linhas principais no eixo X
  panel.grid.minor.x = element_blank()
)

print(grafico_escala_div)

```

Efeito de Escala na Diversidade da Paisagem

Variação contínua e tendência (Média $\pm$ IC 95%)




Figura 2.2: Efeito de escala na diversidade da paisagem ao redor das estações de monitoramento fotográfico.

Resultados com o índice de Shannon (metrica SHDI) nos mostra a heterogeneidade da matriz urbana (Figura 2.2). Existe uma tendência positiva clara: a diversidade da paisagem aumenta conforme o raio de amostragem se expande de 12,5m para 100m (Figura 2.2). É importante notar que, neste caso, o aumento da diversidade não é necessariamente positivo do ponto de vista conservacionista. O aumento do Shannon aqui indica a intrusão de elementos antropogênicos (Uso Humano) na vizinhança da vegetação. A “diversidade” aqui é o registro da mudança entre o ambiente natural e o construído.

O limite superior do intervalo de confiança (IC) para 12,5m termina em aproximadamente 0,28. O limite inferior do IC para 100m começa em aproximadamente 0,30. Como não há sobreposição entre os “crossbars” (IC 95%) desses dois grupos, podemos afirmar com confiança estatística ($p < 0,05$) que a diversidade da paisagem no raio de 100m é significativamente maior que no raio de 12,5m (Figura 2.2). Muitos pontos apresentam SHDI igual a 0 na escala de 12,5m a 50m (Figura 2.2). Isso ocorre porque, em um raio curto, a armadilha fotográfica está inserida em uma “mancha pura” (ex: apenas Cerrado Antrópico ou apenas Uso Humano). A paisagem é homogênea e monótona. Na escala de 100m O valor médio de Shannon sobe para aproximadamente 0,42, com picos atingindo 0,70 (como nos pontos LO_07_0100 e LO_07_0700). Nesta escala, o círculo de amostragem é grande o suficiente para captar a transição entre diferentes classes (ex: o fragmento de vegetação + a calçada).

Os pontos com SHDI alto (perto de 0,7) na escala de 100m são zonas de borda ativa. Estes locais podem atrair animais que utilizam a vegetação para abrigo, mas buscam recursos na matriz urbana (como restos de alimentos humanos ou presas sinantrópicas, como ratos e pombos). A baixa diversidade nas escalas menores (12,5m) confirma que a câmera está “dentro” de um tipo de cobertura. Se um animal é registrado em um ponto onde o Shannon é 0 (escala 12,5m) mas sobe para 0,6 (escala 100m), você tem a prova quantitativa de que aquela espécie está utilizando um fragmento pequeno e altamente influenciado pelo entorno urbano.

2.5.2 Composição

Se o pacote de ecologia espacial simplesmente omite a linha quando a classe não existe no buffer (em vez de reportar 0), a função `mean()` do R calcula a média apenas para os locais onde a classe estava presente. Isto inflaciona artificialmente os valores de `pland` e `cpland`, criando a ilusão de que o campus tem muito mais cobertura do que realmente tem.

```
# Limpar e filtrar os dados
dados_prop <- dados_metricas %>%
  # Filtrar apenas a métrica de porcentagem da paisagem (cpland)
  filter(metric %in% c("cpland", "pland")) %>%
  # Remover linhas que não têm classe definida (ex: métricas de nível de landscape)
  filter(!is.na(class_3)) |>
  tidyr::complete(plot_id, escala_buffer, metric, class_3, fill = list(value = 0))

# Grafico
grafico_escala_efeito <- ggplot(dados_prop,
                                aes(x = escala_buffer, y = value,
                                    color = class_3, fill = class_3)) +

  # 1. Pontos Brutos
  geom_jitter(alpha = 0.3, width = 1.5, size = 1.5) +
  # 2. Crossbar
  # Adicionamos aes(group = escala_buffer) LOCALMENTE.
  # Isso avisa ao ggplot: "Para calcular a média e o bootstrap, agrupe por escala.
  # Mas não estrague a continuidade do eixo X para o resto do gráfico".
  stat_summary(
    aes(group = escala_buffer),
    fun.data = "mean_cl_boot",
    geom = "crossbar",
    alpha = 0.4,
    color = "black",
    linewidth = 0.6
  ) +

  # 3. Linha de Tendência (Loess)
  # Como o agrupamento foi isolado no crossbar, o loess consegue enxergar
  # a distância contínua (ex: o salto maior de 50m para 100m) e desenha a curva.
```

```

stat_smooth(
  method = "loess",
  se = FALSE,
  linewidth = 1.2,
  color = "black" # Forçamos a linha para preto para destacar sobre os pontos coloridos
) +
facet_grid(metric ~ fct_reorder(class_3, value, .fun = mean, .desc = TRUE)) +
scale_color_viridis_d(option = "turbo") +
scale_fill_viridis_d(option = "turbo") +
labs(
  title = "Efeito de Escala na Composição da Paisagem",
  subtitle = "Variação contínua e tendência (Média ± IC 95%)",
  x = "Raio de Amostragem (metros)",
  y = "Proporção na Paisagem (%)"
) +
theme_bw() +
theme(
  legend.position = "none",
  strip.text = element_text(face = "bold", size = 11),
  # Aumentar a clareza visual mantendo apenas as linhas principais no eixo X
  panel.grid.minor.x = element_blank()
)

print(grafico_escala_efeito)

```

Efeito de Escala na Composição da Paisagem

Variação contínua e tendência (Média $\pm$ IC 95%)




Figura 2.3: Efeito de escala na composição da paisagem ao redor das estações de monitoramento fotográfico. A linha contínua negra representa a tendência espacial suavizada (LOESS) da proporção de cobertura, enquanto as barras indicam a média e o intervalo de confiança de 95% (bootstrap) para os raios de amostragem. Os quadros estão ordenados da classe de uso do solo mais dominante para a menos dominante acerca das estações de monitoramento.

Num ecossistema silvestre intacto, a floresta contínua é a matriz, e as estradas ou clareiras humanas são os fragmentos isolados. Em áreas urbanas inclusive no campus Marco Zero, ocorre exatamente o inverso: o ambiente construído (Uso Humano) é o único espaço contínuo e geometricamente íntegro, enquanto a natureza (Cerrado Antrópico) foi reduzida a recortes altamente permeáveis (Figura 2.3). Isto cria um habitat instável e inadequado para espécies silvestres sensíveis, mas extremamente favorável para a fauna sinantrópica que explora as margens da infraestrutura.

A área núcleo quantificada através a métrica cpland não mede apenas a presença física de uma cobertura (como faz o pland), mas testa a sua integridade geométrica, descontando as zonas de transição (efeito de borda). Os valores de área núcleo do uso humano mantêm-se invariavelmente elevados, registrando médias acima de 50% em raios de 25 metros ou mais (Figura 2.3). Isto prova matematicamente que as infraestruturas e áreas de atividade humana não estão fragmentadas. O uso humano funciona como a “matriz imperturbável” do campus, dominando a paisagem com áreas interiores (núcleo) isoladas de outras classes.

O “Cerrado Antrópico” da UNIFAP, embora presente nos pontos de amostragem, carece de in-

tegridade estrutural. Nas escalas menores (12,5m e 25m), o pland frequentemente atinge valores próximos a 100% (ex: Pontos LO_01_0000 e LO_05_0400). Isso ocorre porque a armadilha está fisicamente dentro da mancha de vegetação. No entanto, ao expandir para a escala de 100m, o pland cai drasticamente para valores como 15,05% (Ponto LO_01_0600) ou 5,74% (Ponto LO_07_0300). Enquanto a área total da classe diminui com a escala, o cpland (Core Area) permanece consistentemente baixo. Em muitos pontos, a área de núcleo é quase nula em relação à complexidade da matriz circundante.

A manutenção de valores baixos de cpland sugere que a maior parte do Cerrado Antrópico no campus é composta por “bordas”. Em ecologia de paisagem, quando o cpland é significativamente menor que o pland, entende-se que o fragmento é excessivamente alongado ou pequeno demais para manter condições de interior (microclima estável, menor ruído, menor incidência de espécies invasoras ou domésticas).

A redução expressiva do pland ao aumentar o raio de amostragem demonstra que as manchas de Cerrado são pequenas e estão imersas em uma matriz dominante de “Uso Humano” (edificações, asfalto, áreas desmatadas). No Campus Marco Zero, isso reflete a pressão da infraestrutura universitária sobre os remanescentes naturais. A paisagem deixa de ser “Cerrado com interferência” para se tornar “Urbanização com fragmentos de Cerrado”.

2.5.3 Configuração

```
# Limpar e filtrar os dados
dados_conf <- dados_metricas %>%
  # Filtrar apenas a métrica de porcentagem da paisagem (cpland)
  filter(metric %in% c("ai", "ed")) %>%
  # Remover linhas que não têm classe definida
  filter(!is.na(class_3))

# Grafico
grafico_escala_conf <- ggplot(dados_conf,
                              aes(x = escala_buffer, y = value,
                                  color = class_3, fill = class_3)) +

  # 1. Pontos Brutos
  geom_jitter(alpha = 0.3, width = 1.5, size = 1.5) +
  # 2. Crossbar
  # Adicionamos aes(group = escala_buffer) LOCALMENTE.
  # Isso avisa ao ggplot: "Para calcular a média e o bootstrap, agrupe por escala.
  # Mas não estrague a continuidade do eixo X para o resto do gráfico".
  stat_summary(
    aes(group = escala_buffer),
    fun.data = "mean_cl_boot",
    geom = "crossbar",
    alpha = 0.4,
    color = "black",
```

```

    linewidth = 0.6
  ) +

# 3. Linha de Tendência (Loess)
# Como o agrupamento foi isolado no crossbar, o loess consegue enxergar
# a distância contínua (ex: o salto maior de 50m para 100m) e desenha a curva.
stat_smooth(
  method = "loess",
  se = FALSE,
  linewidth = 1.2,
  color = "black" # Forçamos a linha para preto para destacar sobre os pontos coloridos
) +
facet_grid(metric ~ class_3, scales = "free_y") +
scale_color_viridis_d(option = "turbo") +
scale_fill_viridis_d(option = "turbo") +
labs(
  title = "Efeito de Escala na Configuração da Paisagem",
  subtitle = "Variação contínua e tendência (Média ± IC 95%)",
  x = "Raio de Amostragem (metros)",
  y = "Valores"
) +
theme_bw() +
theme(
  legend.position = "none",
  strip.text = element_text(face = "bold", size = 11),
  # Aumentar a clareza visual mantendo apenas as linhas principais no eixo X
  panel.grid.minor.x = element_blank()
)

print(grafico_escala_conf)

```

Efeito de Escala na Configuração da Paisagem

Variação contínua e tendência (Média $\pm$ IC 95%)




Figura 2.4: Efeito de escala na configuração da paisagem ao redor das estações de monitoramento fotográfico. A linha contínua negra representa a tendência espacial suavizada (LOESS) da proporção de cobertura, enquanto as barras indicam a média e o intervalo de confiança de 95% (bootstrap) para os raios de amostragem. Os quadros estão ordenados da classe de uso do solo mais dominante para a menos dominante acerca das estações de monitoramento.

A configuração da paisagem do Campus Marco Zero (Figura 2.4) revela que os remanescentes de Cerrado e Campo Sujo possuem alta coesão interna (AI 95%), mas sofrem com uma severa pressão de borda nas escalas locais, especialmente o Campo Sujo ($ED > 400$ m/ha). A redução do ED com o aumento da escala espacial demonstra que a complexidade estrutural da vegetação é rapidamente substituída pela homogeneidade da matriz construída, caracterizando um cenário de fragmentação onde os habitats naturais funcionam como ilhas compactas sob forte influência externa.

O índice de agregação (AI) mede o quão próximos ou “agrupados” estão os pixels de uma mesma classe (vai de 0 a 100%). Em todas as classes (Campo Sujo, Cerrado Antrópico e Uso Humano), o AI é extremamente alto e estável (próximo a 100%). Isso indica que a vegetação no campus não está distribuída de forma “salpicada” ou fragmentada em minúsculos pontos isolados (como gramados raleados). Pelo contrário, onde a vegetação existe, ela forma blocos compactos - pelo menos com uma classificação em 3 classes.

O Densidade de Borda (ED) mede a quantidade de bordas (contato entre diferentes classes) em relação à área total (metros por hectare). É um dos principais indicadores de fragmentação. Campo

Sujo (O mais fragmentado), apresenta os valores de ED mais altos na escala local (12,5m), chegando a 400-600 m/ha. Isso mostra que as áreas de Campo Sujo são manchas menores ou com formatos muito irregulares, onde quase tudo é “borda”. Conforme o raio aumenta para 100m, o ED cai para ~150 m/ha, indicando que essas manchas estão imersas em uma matriz que “dilui” essa borda. Para o classe de Uso Humano (a matriz estável) o ED é o mais baixo e estável (perto de 100 m/ha). Isso ocorre porque as áreas construídas no campus (blocos, estacionamentos) tendem a ter formatos geométricos e contínuos, gerando menos “perímetro de borda” por unidade de área do que a vegetação natural, que é mais irregular.

2.5.4 Implicações para a Fauna:

- Espécies Especialistas:
Provavelmente estão ausentes ou apenas de passagem, pois não encontram “área de núcleo” (cpland) suficiente para estabelecer território ou reprodução segura.
- Espécies Generalistas/Sinantrópicas:
São favorecidas. A baixa área de núcleo e a alta permeabilidade da matriz urbana facilitam a presença de espécies que toleram a presença humana (ex: roedores sinantrópicos).
- Conectividade:
O Cerrado Antrópico no campus funciona mais como stepping stones (pontos de parada) do que como um corredor ecológico funcional, devido à rápida perda de representatividade (pland) em escalas espaciais maiores.

2.6 Conclusão da Análise

A paisagem do Campus Marco Zero é escala-dependente. O que parece um “bloco de vegetação” em uma análise de curto alcance (12,5m), revela-se uma paisagem multifacetada em escala de 100m. Para a fauna, isso significa que não existem refúgios isolados da influência urbana; todo animal que transita pelo campus está a poucos metros de uma mudança na composição da paisagem.

Para entender os processos ecológicos no campus Marco Zero que dependam minimamente de áreas naturais, uma escala de pelo menos 50 metros é o limite mínimo viável.

Aqui estão os dois motivos técnicos que fundamentam a conclusão:

Estatisticamente viável:

Abaixo de 50 metros (nos raios de 12,5m e 25m), a área núcleo de Cerrado (cpland) para muitas câmaras é pura e simplesmente zero. Estatisticamente, é impossível calcular se um animal prefere a vegetação se a sua variável de habitat for apenas uma coluna cheia de zeros. Ao alargar para 50 metros, o cpland atinge o seu pico de representatividade (cerca de 24,8% de média), introduzindo a variabilidade numérica mínima necessária para os modelos funcionarem.

O Comportamento do Animal:

Uma escala de 50 a 100 metros reflete a realidade de que um animal > 1kg dentro do campus precisa de “caminhar mais” ou “olhar mais longe” para encontrar um fragmento seguro. Ele não toma a

decisão de forragear com base nos 10 metros ao seu redor (que são puramente borda e perturbação), mas sim avaliando o polígono maior.

Esta escolha de mais de 50 metros é geral e não leva em conta as características dos animais. Se o seu objetivo for modelar a presença de cães errantes, gatos ou pombos (fauna sinantrópica), escalas menores de 25 metros continuam a ser potencialmente explicativas, porque esses animais podem tomar as suas decisões baseados na presença imediata de infraestrutura e calçadas.

3 Escala de Efeito na Ocorrência de Fauna Doméstica

 Capítulo em Desenvolvimento

Aviso:

Este capítulo é um trabalho em andamento. Os exemplos de código e o texto ainda estão sendo refinados. Você pode encontrar alguns espaços em branco, rascunhos, erros gramaticais, mas estou trabalhando ativamente para finalizá-lo. Feedbacks e sugestões são sempre bem-vindos!

3.1 Introdução

A ecologia de paisagens urbana investiga como a configuração e a composição do habitat influenciam a biodiversidade. No contexto amazônico, áreas como o Campus Marco Zero da UNIFAP (Macapá, Brasil) representam mosaicos complexos onde a fauna doméstica (*Canis familiaris* e *Felis catus*) interage com fragmentos remanescentes de cerrado.

Um conceito central aqui é a **Escala de Efeito**: a escala espacial na qual a relação entre a estrutura da paisagem e a resposta biológica é mais forte. Este capítulo demonstra como identificar essa escala e analisar a coocorrência dessas espécies usando R.

3.2 Configuração do Ambiente e Dados

Utilizaremos o ecossistema `tidyverse` para manipulação, `sf` para dados espaciais e pacotes de modelagem estatística.

```
# 1. Spatial Engines
library(terra)
library(sf)

# 2. Data Manipulation & Grammar
library(tidyverse)
library(broom)

# 3. Analytical Models
library(AICcmodavg) # Para comparação de modelos
```

```
library(MuMIn)

# 4. Cartography & Visualization
library(patchwork) # Para organizar gráficos
```

Dados

```
# Ler o arquivo com metricas
metricas <- read.csv("data/tabela_metricas_final.csv")
# Ler o arquivo com presença-ausência
especies <- read.csv("data/ep_species_pa.csv")
# Limpeza e padronização de IDs
especies <- especies |>
  rename(plot_id = instal_ponto)
```

Preparação da Paisagem As métricas calculadas via landscapemetrics precisam ser organizadas. Focaremos na métrica pland (porcentagem da classe) para a classe “uso humano”, que é frequentemente um preditor forte para espécies domésticas.

```
# Filtrando a métrica PLAND para áreas de Uso Humano
df_pland_humano <- metricas |>
  tidyr::complete(plot_id, metric, class_3, escala_buffer, fill = list(value = 0)) |>
  filter(metric == "pland", class_3 == "uso humano") |>
  select(plot_id, escala_buffer, value) |>
  rename(pland_humano = value)

# Preparação: Deixando os dados em formato "longo" (uma coluna para espécie)
# Isso permite agrupar tudo de uma vez só!
df_longo <- especies |>
  select(plot_id, calu, feca) |>
  pivot_longer(cols = c(calu, feca), names_to = "especie", values_to = "presenca") |>
  left_join(df_pland_humano, by = "plot_id")
```

3.3 Análise da Escala de Efeito

Para identificar a escala de efeito, testamos a ocorrência da espécie contra a métrica da paisagem em diferentes buffers (12.5m, 25m, 50m, 100m). A escala com o menor AIC (Akaike Information Criterion) é considerada a escala de efeito.

```
# 1. O Fluxo Nest-Map-Unnest (O "Coração" da análise)
# Imagine isso como: Agrupar -> Criar Gavetas -> Rodar Modelo -> Tirar da Gaveta
resultados_modelos <- df_longo |>
  group_by(especie, escala_buffer) |>
```

```

nest() |> # Cria uma "gaveta" (list-column) para cada combinação
mutate(
  # Aplicamos o GLM dentro de cada gaveta
  modelo = map(data, ~glm(presenca ~ pland_humano, data = .x, family = binomial)),
  # Usamos o broom::glance para extrair estatísticas básicas
  resumo = map(modelo, glance),
  # Adicionamos o AICc manualmente usando o MuMIn
  aicc = map_dbl(modelo, MuMIn::AICc)
) |>
unnest(resumo) |> # Transforma as estatísticas do broom em colunas
group_by(especie) |>
mutate(limiar = min(aicc) + 2) |>
ungroup()

```

Agora comparação dos resultados.

```

resultados_modelos |>
mutate(especie = ifelse(especie == "calu", "Cães", "Gatos")) |>
ggplot(aes(x = escala_buffer, y = aicc)) +
  geom_line(aes(color = especie), linewidth = 1.8) +
  geom_point(aes(fill = especie), size = 6, shape = 21) +
  geom_hline(aes(yintercept = limiar), linetype = "dashed") +
  scale_color_manual(values = c("Cães" = "#0072B2", "Gatos" = "#D55E00")) +
  scale_fill_manual(values = c("Cães" = "#0072B2", "Gatos" = "#D55E00")) +
  facet_wrap(~ especie, scales = "free_y") +
  labs(title = "Escala de Efeito", x = "Raio (m)", y = "AICc") +
  theme_bw() +
  theme(legend.position = "none")

```




Figura 3.1: Identificação da escala de efeito para a ocorrência de cães (*Canis familiaris*) e gatos (*Felis catus*) em relação à porcentagem de áreas de uso humano (métrica PLAND) no Campus Marco Zero da UNIFAP, Macapá-AP. As curvas representam a variação do Critério de Informação de Akaike corrigido (AICc) em quatro escalas espaciais (raios de 12.5, 25, 50 e 100 metros). A linha horizontal tracejada indica o limiar de parcimônia ($\Delta AICc$ 2); modelos abaixo desta linha são considerados estatisticamente competitivos. Observa-se que a ocorrência de cães é melhor explicada por processos locais (12.5 a 50 m), enquanto a ocorrência de gatos responde de forma mais forte à paisagem em uma escala mais ampla (100 m).

3.3.0.1 Coocorencias

```
# 1. Preparação: Unindo dados bióticos (cães e gatos) com a paisagem
df_cooc_pre <- especies |>
  select(plot_id, calu, feca) |>
  left_join(df_pland_humano, by = "plot_id")

# 2. Modelagem com Intervalos de Confiança de 95%
cooc_robusto <- df_cooc_pre |>
  group_by(escala_buffer) |>
  nest() |>
  mutate(
    modelo = map(data, ~glm(feca ~ calu + pland_humano, data = .x, family = binomial)),
    # conf.int = TRUE calcula automaticamente os limites inferior e superior
  )
```

```

    coefs = map(modelo, ~tidy(.x, conf.int = TRUE, conf.level = 0.95))
  ) |>
  unnest(coefs) |>
  filter(term == "calu")

# 3. Visualização
ggplot(cooc_robusto, aes(x = as.factor(escala_buffer), y = estimate)) +
  # Adiciona uma área sombreada para incerteza (opcional, mas estético)
  geom_hline(yintercept = 0, linetype = "dashed", color = "red", size = 1) +
  # geom_errorbar desenha os ICs de 95% robustos
  geom_errorbar(aes(ymin = conf.low, ymax = conf.high),
                width = 0.2, size = 0.8, color = "purple") +
  geom_point(size = 4, color = "purple") +
  # Formatação para livro
  labs(
    title = "Interação Biótica: Cães vs Gatos",
    subtitle = "Intervalos de Confiança (IC) de 95% calculados via verossimilhança",
    x = "Escala de Buffer (m)",
    y = "Efeito da Presença de Cães (Log-odds)",
    caption = "Se o intervalo cruza a linha vermelha (zero), a interação não é significativa."
  ) +
  theme_light(base_size = 12)

```




Figura 3.2: Análise multiescalar da interação biótica entre cães e gatos no Campus Marco Zero da UNIFAP, Macapá-AP. Os pontos representam as estimativas de inclinação (coeficientes Log-odds) da presença de cães sobre a probabilidade de ocorrência de gatos, controladas estatisticamente pela porcentagem de áreas de uso humano (métrica PLAND). As barras verticais indicam os intervalos de confiança (IC) de 95% calculados via perfil de verossimilhança. A linha tracejada vermelha no valor zero representa a hipótese nula (ausência de interação).

O gráfico sugere que outros fatores (infraestrutura do campus e/ou a oferta de comida) é uma força mais poderosa na estruturação da comunidade de fauna doméstica do que a competição direta entre as duas espécies. Em todas as escalas testadas (12,5m a 100m), os intervalos de confiança de 95% (barras roxas) cruzam a linha do zero (linha vermelha tracejada). Isso indica que, estatisticamente, não há evidência de uma interação forte (atração ou repulsão) entre cães e gatos que seja independente da infraestrutura urbana no Campus Marco Zero. O fato de a interação ser nula sugere que ambas as espécies podem estar respondendo de forma independente aos recursos oferecidos pelo campus (comida, abrigo em prédios), onde a disponibilidade de recursos no habitat é o fator principal que dita onde os animais estão, e não a presença um do outro.

Ao interpretarmos os resultados de coocorrência, devemos olhar para dois processos que operam simultaneamente no campus Hotspots de Recursos e Filtragem Ambiental

- Hotspots de Recursos (Atração Comum):

A ausência de segregação (intervalos cruzando o zero) sugere que a distribuição de recursos antrópicos (pontos de alimentação voluntária, lixeiras abertas e o entorno do Restaurante Universitário - RU) exerce uma força de atração superior à força de repulsão entre as espécies. Em ecologia urbana, o recurso (comida) frequentemente “força” a sobreposição de nicho espacial, mesmo entre predadores e competidores.

- Filtragem Ambiental vs. Seleção de Micro-habitat:
Enquanto o “uso humano” (PLAND) atua como um filtro macro (definindo quem consegue viver no campus), a localização fina dos indivíduos é ditada pela oferta de subsídios energéticos. Cães e gatos na UNIFAP não estão apenas “onde há prédios”, eles estão onde há energia disponível. Se os intervalos de confiança são largos, isso indica que essa oferta de recursos é heterogênea e não foi totalmente capturada apenas pela métrica de cobertura do solo.

3.3.1 Rumo ao Desenho Quase-Experimental

Para sair de uma análise puramente descritiva e caminhar para uma inferência causal mais robusta, podemos implementar um desenho quase-experimental com os dados. Um experimento verdadeiro (sortear onde haverá cães ou humanos) é impossível, mas o “quase-experimento” aproveita variações existentes.

A. Amostragem Estratificada por Gradiente de Recurso.

Implementem um desenho de Contraste de Tratamentos com dois grupos. Grupo Tratamento (Alta Oferta): pontos num raio de 50m do RU, lixeiras centrais e pontos de alimentação. Grupo Controle (Baixa Oferta): pontos de vegetação de cerrado remanescente ou mais distante pontos de alimentação. Comparem se a “Escala de Efeito” muda entre esses dois grupos. A hipótese é que, em áreas de alta oferta, a coocorrência é positiva (agregação), e em áreas de baixa oferta, a competição aparece (segregação).

B. Aproveitamento de “Experimentos Naturais” (BACI - Before-After-Control-Impact).

O campus passa por mudanças cíclicas que podem ser tratadas como tratamentos experimentais. Período de Férias vs. Período Letivo, onde a drástica redução na produção de resíduos e na circulação de pessoas no RU durante as férias é um “experimento de remoção de recurso”. Se a segregação entre cães e gatos aumentar durante as férias (quando há menos comida), vocês provam que o recurso humano é o mediador da paz (coexistência) entre as espécies. Comparar Amostragem Estratificada por Gradiente de Recurso nas épocas diferentes.

C. Mapeamento de Pontos de Alimentação como Covariável.

Adicionem uma camada de distância euclidiana até o ponto de recurso mais próximo no modelo (RU, lixeiras centrais e pontos de alimentação). No código R, em vez de usar apenas métricas da paisagem, usem `dist_recurso`. Dica Teórica: Se o AICc do modelo com `dist_recurso` for menor que o de `pland`, vocês demonstram que a ecologia das espécies domésticas na UNIFAP é guiada por pontos focais de energia e não apenas pela estrutura física da paisagem.

3.4 Conclusão

Embora a ocorrência (presença-ausência) não mostre segregação, a análise de abundância relativa (frequência de fotos) poderia revelar padrões diferentes, como uma maior concentração de ambas as espécies em torno de “ilhas de recursos” (ex: Restaurante Universitário).

Avançar da Ecologia de Paisagens descritiva para o desenho quase-experimental permitira que a UNIFAP não seja apenas o local de estudo, mas um laboratório vivo onde testamos teorias sobre como subsídios humanos alteram as regras básicas das interações bióticas na Amazônia urbana.

4 Summary

In summary, this book has no content whatsoever.

1 + 1

[1] 2

References

Hesselbarth, Maximilian H. K., Marco Sciaini, Kimberly A. With, Kerstin Wiegand, e Jakub Nowosad. 2019. “landscapemetrics: an open-source R tool to calculate landscape metrics”. *Ecography* 42: 1648–57. <https://doi.org/10.1111/ecog.04617>.